Contact Discovery Pipeline — Техническое решение

Задача: Извлечение контактной информации (email, телефон, соцсети) для базы 1M+ записей
Входные данные: `имя + фамилия + URL статьи` (контактов на странице нет)
Целевые персоны: бизнес-персоны (LinkedIn и профильные ресурсы как основные источники)
Критерии: дёшево · быстро · качественно

---

1. Архитектура пайплайна

1.1 Ключевой принцип: Tiered Early-Exit Pipeline

Каждая запись проходит уровни от дешёвого к дорогому. Как только контакт найден — запись **немедленно выходит из пайплайна**, не расходуя бюджет на дорогие уровни. Это снижает среднюю стоимость обработки в 3–4x по сравнению с единым дорогим API на всю базу.

1.2 Схема потоков данных

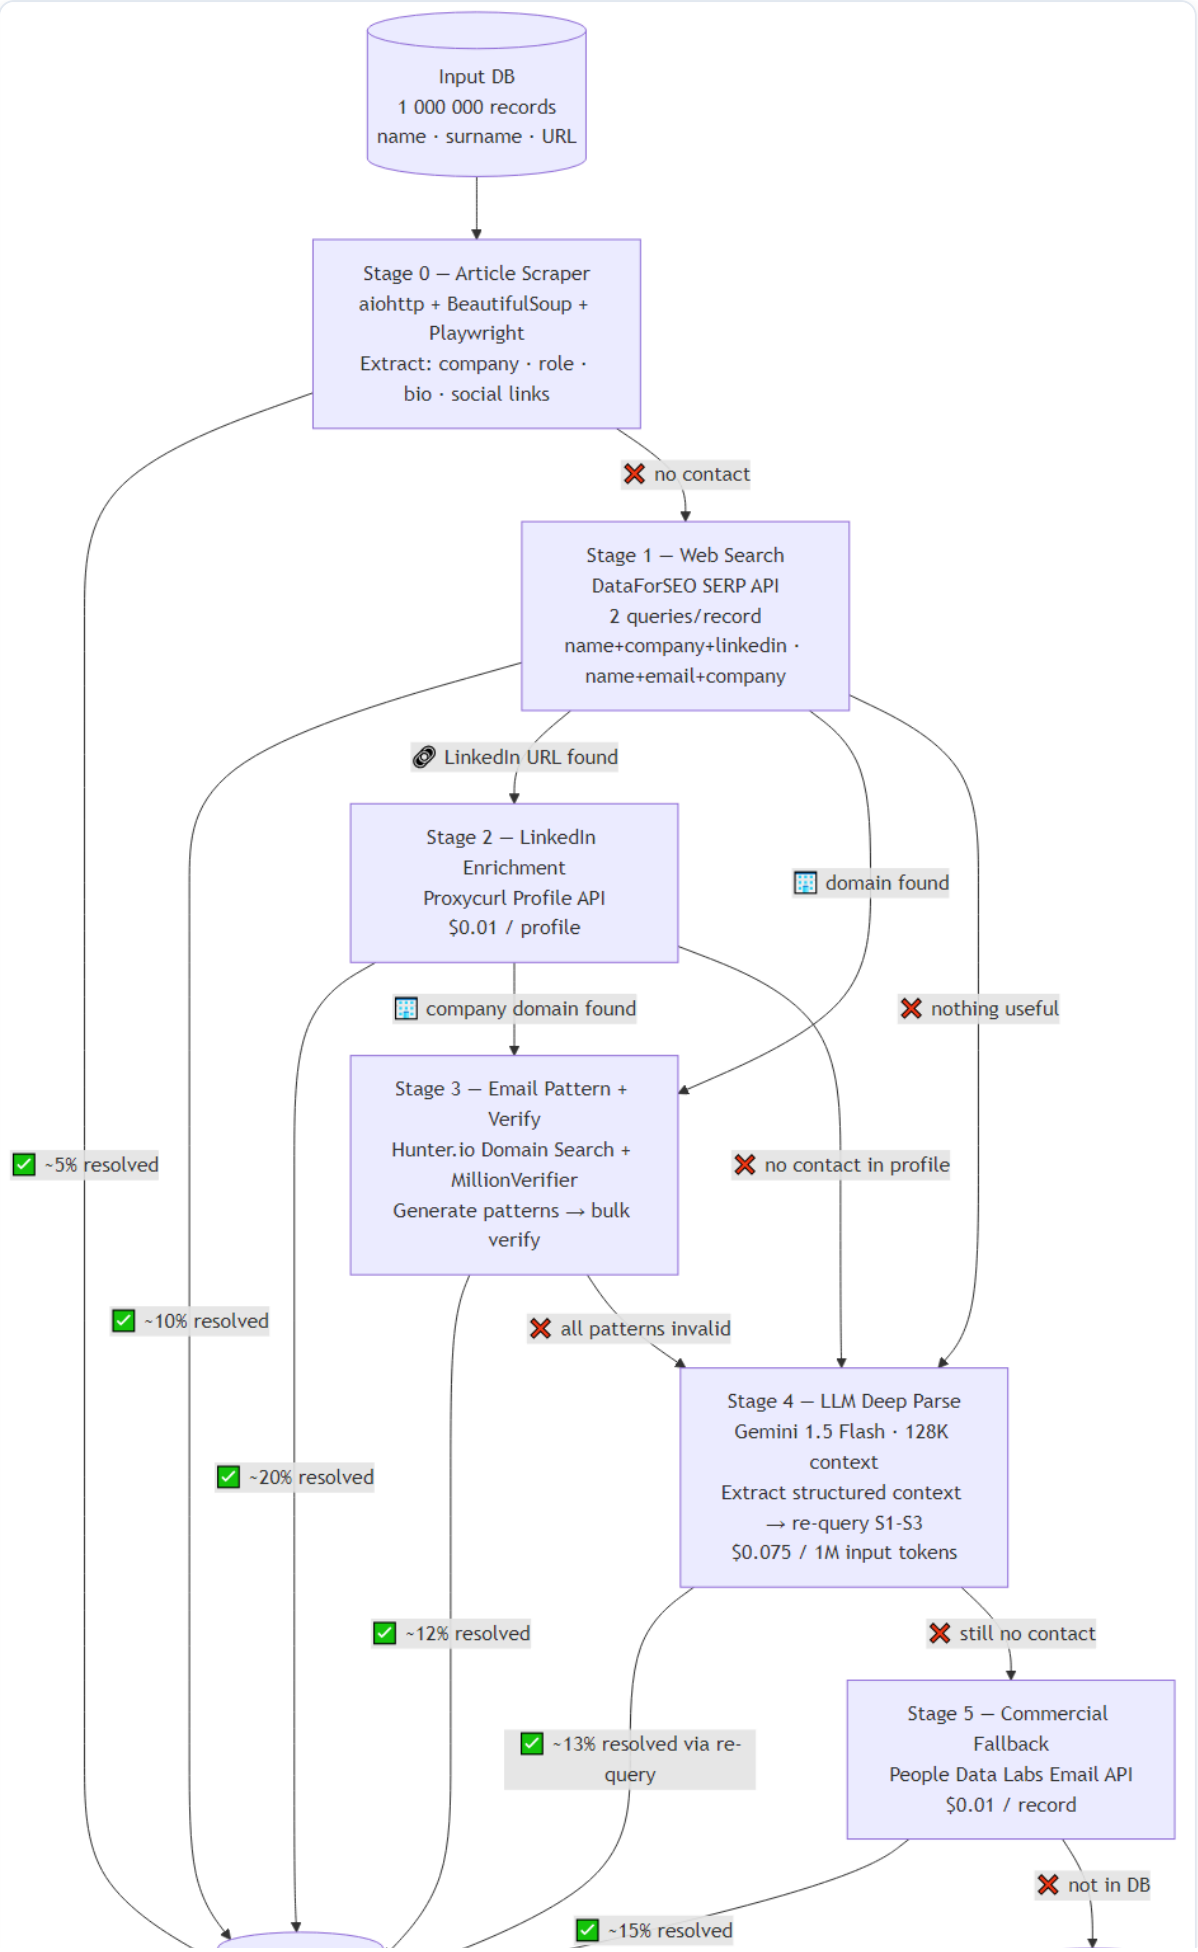
Input DB
1 000 000 records
name · surname · URL
Stage 0 — Article Scraper
aiohttp + BeautifulSoup + Playwright
Extract: company · role · bio · social links
no contact
Stage 1 — Web Search
DataForSEO SERP API
2 queries/record
name+company+linkedin · name+email+company
LinkedIn URL found
Stage 2 — LinkedIn Enrichment
Proxycurl Profile API
$0.01 / profile
domain found
company domain found
nothing useful
Stage 3 — Email Pattern + Verify
Hunter.io Domain Search + MillionVerifier
Generate patterns → bulk verify
~5% resolved
no contact in profile
~10% resolved
all patterns invalid
Stage 4 — LLM Deep Parse
Gemini 1.5 Flash · 128K context
Extract structured context → re-query S1-S3
$0.075 / 1M input tokens
~20% resolved
~12% resolved
still no contact
~13% resolved via re-query
Stage 5 — Commercial Fallback
People Data Labs Email API
$0.01 / record
not in DB
~15% resolved

1.3 Описание каждого уровня

Stage 0 — Article Scraper (бесплатно)

- Парсим статью по URL из базы
- Ищем: ссылки на LinkedIn/Twitter/GitHub/личный сайт, email-адреса через regex, структурированные данные (JSON-LD, OpenGraph, hCard)
- Для JS-рендеринга: Playwright (headless Chromium), только для ~15% страниц, определяемых по Content-Type / размеру HTML
- **Цель:** вытащить максимум контекста (компания, должность, индустрия) даже если контакта нет — этот контекст используется на следующих стадиях
- **Hit rate:** ~5% (прямые контакты редки, но контекст извлекается для ~80% записей)

Stage 1 — Web Search via DataForSEO

- Два поисковых запроса на запись:
  - `"Иван Петров" "Company Name" site:linkedin.com`
  - `"Иван Петров" "Company Name" email contact`
- DataForSEO выбран вместо Google Custom Search API в 5x дешевле ($0.0006 vs $0.003/запрос)
- Результаты: LinkedIn URLs, явные email-адреса в сниппетах, профили на профильных платформах
- **Hit rate:** ~10% прямых контактов + ~35% LinkedIn URLs для Stage 2

Stage 2 — LinkedIn via Proxycurl

- Входные данные: LinkedIn URL из Stage 1
- Proxycurl Profile Endpoint: возвращает email (если публичен), телефон, другие соцсети, место работы
- Proxycurl — единственный стабильный легальный способ получить данные LinkedIn без нарушения ToS (официальный партнёрский статус)
- Рассматривали: RocketReach ($0.02–0.05/запись), Lusha (дороже), прямой скрапинг LinkedIn (нарушение ToS + блокировки)
- **Hit rate:** ~57% из профилей имеют контактные данные

Stage 3 — Email Pattern Generation + Verification

- Условие: известен корпоративный домен компании
- Генерируем 5–7 паттернов: `ivan.petrov@`, `ipetrov@`, `ivan@`, `i.petrov@`, `petrov@domain.com`
- Верификация через MillionVerifier (bulk API): SMTP-проверка без отправки письма

- Hunter.io Domain Search как дополнение: находит реальные паттерны компании через известные email-адреса
- **Hit rate:** ~40% для записей с известным доменом

Stage 4 — LLM Deep Parse (Gemini 1.5 Flash)

- Запускается для записей, где Stages 0–3 не нашли контакт
- Задача LLM: глубокий анализ статьи (128K context window → весь HTML без обрезки) → структурированный вывод:

```
{
  "company": "...",
  "company_domain": "...",
  "role": "...",
  "industry": "...",
  "alternative_names": [...],
  "mentioned_platforms": [...],
  "search_queries": ["query1", "query2", "query3"]
}
```

- Возвращаем в Stage 1–3 с обогащёнными данными
- **Почему Gemini 1.5 Flash, а не другие:**
  - Цена: $0.075/1M input tokens — в 10x дешевле Claude Haiku ($0.80/1M)
  - Контекстное окно: 1M токенов (избыточно, но страховка для длинных страниц)
  - Скорость: один из самых быстрых inference API на рынке
  - Для простой structured extraction не нужен Opus/Sonnet — Flash справляется с точностью >95%

Stage 5 — Commercial Fallback (People Data Labs)

- Для ~25–30% записей, не найденных на Stages 0–4
- PDL — одна из крупнейших коммерческих баз (3B+ профилей), хорошо покрывает бизнес-персоны
- PDL Email Lookup API: имя + компания → email
- Рассматривали: Apollo.io ($0.02–0.05/record = в 2–5x дороже), Clearbit (deprecated/Hubspot), ZoomInfo (enterprise-only, дорого)
- **Hit rate:** ~50% из оставшихся записей

1.4 Технический стек

Компонент	Технология	Обоснование
Язык	Python 3.11+	ecosystem для data processing, async-first
Task queue	Celery + Redis	distributed workers, retry logic, priority queues
HTTP	aiohttp (async)	10–50x faster vs requests для I/O-bound операций
JS rendering	Playwright	headless Chromium, только для необходимых страниц
Database	PostgreSQL	JSONB для гибкого хранения частично найденных данных
Monitoring	Python logging + Grafana (опционально)	базовый мониторинг прогресса
Cloud	AWS Spot instances	c5.xlarge: $0.04/hour, 75% дешевле on-demand

Архитектура воркеров:

```
Redis (job queue)
    ↓
Celery Orchestrator
    ├── scraper_worker × 4     (Stage 0)
    ├── search_worker × 4      (Stage 1)
    ├── linkedin_worker × 2    (Stage 2, rate-limited)
    ├── email_worker × 4       (Stage 3)
    ├── llm_worker × 2         (Stage 4)
    └── fallback_worker × 2    (Stage 5)
    ↓
PostgreSQL (results)
```

Throughput: при 50 req/s по всем воркерам → 1M записей за ~56 часов (~2.5 дня)
Увеличение до 100 req/s сокращает до ~28 часов (add воркеров, упирается в rate limits API)

---

2. Расчёт стоимости на 1M строк

2.1 Детализация по уровням

Уровень	Сервис	Тариф	Кол-во вызовов	Стоимость
Stage 0	Proxies (Bright Data datacenter)	$1/GB	1M × ~50KB = 50GB	**$50**
Stage 0	Playwright rendering (15% страниц)	compute	~150K, включено в EC2	**$0**
Stage 1	DataForSEO SERP API	$0.0006/req	1M × 2 запроса = 2M	**$1,200**
Stage 2	Proxycurl Profile API	$0.01/profile	~350K LinkedIn URLs	**$3,500**
Stage 3	MillionVerifier bulk	$269/1M верификаций	~1.5M паттернов	**$405**
Stage 3	Hunter.io Domain Search	$0.003/домен	~200K доменов	**$600**
Stage 4	Gemini 1.5 Flash (input)	$0.075/1M tokens	300K × 2,500 tok = 750M	**$56**
Stage 4	Gemini 1.5 Flash (output)	$0.30/1M tokens	300K × 400 tok = 120M	**$36**
Stage 4	DataForSEO re-query	$0.0006/req	300K × 2 = 600K	**$360**
Stage 4	Proxycurl (новые LinkedIn URLs)	$0.01/profile	~100K	**$1,000**
Stage 5	People Data Labs Email API	$0.01/record	~250K	**$2,500**
Infra	AWS EC2 Spot (c5.xlarge × 4, ~72h)	$0.04/h	4 × 72h	**$11**
Infra	AWS RDS t3.micro + Redis	~$0.03/h	2 × 72h	**$5**
Буфер	Ошибки, повторы, тесты	—	~10% overhead	**$900**
			ИТОГО	**~$10,623**

2.2 Стоимость на запись

Метрика	Значение
Стоимость 1M строк	~$10,000–11,000
Стоимость 1 записи	**~$0.010–0.011**
Стоимость 1 найденного контакта (при 80% hit rate)	~$0.013–0.014

2.3 Альтернативный сценарий: Lean (без коммерческих API)

Если бюджет критичен, можно исключить Stage 5 (PDL) и сократить Stage 2:

Компонент	Стоимость
Scraping + Search	~$1,300
Proxycurl (топ-200K по уверенности)	~$2,000
Email verification	~$400
Gemini Flash	~$500
ИТОГО Lean	**~$4,200**

Компромисс: hit rate падает до ~55–60% vs ~80% в основном сценарии.
Для высокоценных баз (B2B leads) основной сценарий окупается: каждый найденный контакт стоит $0.013.

---

3. Ресурсы и сроки реализации

3.1 Команда

Роль	FTE	Задачи
Backend Engineer (Python)	1.0	Весь пайплайн, интеграции API
DevOps / Cloud	0.2	Настройка AWS, мониторинг

Для данного проекта достаточно **1 человека** при частичной DevOps-поддержке.

3.2 Timeline разработки

```
Неделя 1
├── Настройка инфраструктуры (Redis, PostgreSQL, Celery)
├── Stage 0: Article scraper (sync + async, Playwright fallback)
└── Stage 1: DataForSEO интеграция + парсинг результатов

Неделя 2
├── Stage 2: Proxycurl интеграция
├── Stage 3: Email pattern generation + MillionVerifier
└── Stage 4: Gemini 1.5 Flash интеграция + prompt engineering

Неделя 3
├── Stage 5: PDL интеграция
├── Orchestration: early-exit логика, retry, dead-letter queue
├── Мониторинг прогресса + метрики качества
└── Пилотный запуск на 10K записях + калибровка

Неделя 4
└── Полный прогон 1M строк (~2.5–3 дня процессинга)
```

Итого: 3 недели разработки + ~3 дня процессинга

3.3 Инфраструктурные требования

- AWS: EC2 Spot (c5.xlarge × 4–8) + RDS t3.micro + ElastiCache t3.micro
- Исходная БД: PostgreSQL / любой SQL/NoSQL с поддержкой bulk reads
- Исходящий IP: ротируемые proxies (Bright Data / Oxylabs) для scraping
- API ключи: DataForSEO, Proxycurl, Hunter.io, MillionVerifier, PDL, Google AI (Gemini)

---

4. Оценка качества и ограничения

4.1 Ожидаемые метрики качества

Тип контакта	Hit rate	Точность найденных
Email (рабочий)	55–65%	90–95% (после SMTP-верификации)
LinkedIn profile	50–65%	~99%
Телефон	15–25%	70–80% (часто общий офисный)
Twitter / X	20–35%	95%
Хотя бы один контакт	**75–85%**	—

Факторы, влияющие на качество:

- Публичность персоны: топ-менеджеры крупных компаний → hit rate >85%
- Менее известные персоны → hit rate ~50–60%
- Год публикации статьи: старые статьи → больше устаревших данных

4.2 Технические ограничения

Ограничение	Описание	Митигация
Rate limits	DataForSEO: 1000 req/min; Proxycurl: 200 req/min	Throttling в Celery, priority queues
Устаревшие данные	Человек сменил компанию / email	Дата верификации в output, периодический refresh
Омонимы	Два разных человека с одинаковым именем	Cross-check по контексту статьи + компании через LLM
Закрытые источники	LinkedIn анонимизирует часть данных	Proxycurl как единственный легальный обходной путь
JS-блокировки	Cloudflare / антибот-защита	Playwright + proxy rotation + exponential backoff

4.3 Ethical Scraping & Platform Compliance

Это принципиальный раздел. Пайплайн должен работать в рамках правил платформ и законодательства:

- **robots.txt:** перед скрапингом каждого домена парсим `robots.txt` и соблюдаем `Crawl-Delay`. Домены с явным запретом на скрапинг — исключаем или обрабатываем только через официальные API (Proxycurl для LinkedIn)
- **Rate limiting:** намеренно ограничиваем throughput до допустимых лимитов каждого сервиса. Aggressive scraping = IP-бан + деградация качества
- **LinkedIn:** не скрапим напрямую. Только через Proxycurl, который работает в рамках партнёрского соглашения. Прямой скрапинг LinkedIn нарушает ToS и создаёт юридические риски (HiQ Labs v. LinkedIn)
- **GDPR / Privacy:** собранные контакты — персональные данные в соответствии с GDPR. Если конечный пользователь — европейская компания, требуется: правовое основание для обработки (legitimate interest / consent), возможность opt-out, retention policy. Рекомендуется юридическая проверка перед запуском в EU
- **CAN-SPAM / PECR:** использование собранных email для cold outreach регулируется. Это ответственность оператора базы, не пайплайна

Ключевой принцип: пайплайн собирает только публично доступную информацию, через легальные каналы, с соблюдением rate limits. Это отличает инженерное решение от массового спам-инструмента.

5. Итоговое резюме

Параметр	Значение
Стоимость 1M строк	~$10,000–11,000
Стоимость 1 записи	~$0.010
Hit rate (любой контакт)	75–85%
Email hit rate	55–65%
Срок разработки	3 недели (1 инженер)
Срок обработки 1M	2.5–3 дня
Ключевые технологии	Python · Celery · Gemini 1.5 Flash · DataForSEO · Proxycurl · PDL

Сильные стороны подхода:

- Tiered early-exit: платим только за то, что нужно
- Gemini 1.5 Flash как LLM: в 10x дешевле аналогов при достаточной точности для extraction-задач
- Proxycurl как единственный compliant путь к LinkedIn-данным
- Modular: каждый stage можно заменить/улучшить независимо

Альтернатива «всё в одном»:
Apollo.io или ZoomInfo на весь объём: $20,000–50,000 за 1M записей при меньшей гибкости и той же покрываемости. Tiered pipeline в 2–5x дешевле.

Contact Discovery Pipeline — Техническое решение · 2024